

CASO PRÁCTICO · TEMA 16 · MACHINE LEARNING

Del comedero al cliente fiel

Pipeline de Machine Learning para la estrategia de clientes en el relanzamiento de Qelux

Claudio Abreu Afonso · EBIS Business Techschool

CONTEXTO DE NEGOCIO

Una marca real que no conocía a sus clientes

Qelux es una marca española de productos premium para mascotas, fundada por el autor, que vendió en Amazon FBA y hoy está en pausa.

En Amazon, **Amazon es dueño del cliente**: no sabes quién te compra, quién repite ni quién se va.

El relanzamiento con **e-commerce propio** y tiendas físicas exige una estrategia de clientes basada en datos desde el día uno.



ENFOQUE DEL PROYECTO

Modelamos cómo compran los clientes, no qué compran

Proxy

Qelux aún no tiene histórico propio: usamos un **e-commerce de referencia** (UCI Online Retail, Reino Unido, 2010-2011).

No supervisado

¿Qué **tipos de clientes** existen según su comportamiento de compra?

Supervisado

¿Qué clientes **no volverán** a comprar en los próximos 90 días?

Las variables son de comportamiento (recencia, frecuencia, gasto…), así que la **metodología se traslada a Qelux**. Los números concretos se recalibrarán con sus datos.

DATOS Y LIMPIEZA

De 541.909 transacciones a 388.098 líneas limpias

Paso de limpieza	Eliminadas	Quedan
Sin identificador de cliente	135.080	406.829
Líneas de cancelación («C»)	8.905	397.924
Compras anuladas por cancelación	3.188	394.736
Cantidad o precio ≤ 0	37	394.699
Códigos que no son producto	1.463	393.236
Duplicados exactos	5.138	388.098

4.322
clientes tras la limpieza

71,6 %
del dataset original
se conserva

HALLAZGO · CONCENTRACIÓN DEL GASTO

1 % → 30 %

de los clientes (43)

del gasto total

Patrón de Pareto: perder a unos pocos clientes clave cuesta muchísimo. Por eso merece la pena **detectar la fuga a tiempo**.

DATASET POR CLIENTE

Una fecha de corte para no ver el futuro

PASADO · dic-2010 → 8-sep-2011

10 variables por cliente (X): recencia, frecuencia, gasto, ticket medio, antigüedad, días entre compras, productos distintos, unidades por pedido, cancelaciones, país.

FUTURO · 90 días

Target (y): **Fuga = 1** si el cliente no vuelve a comprar en la ventana.

3.355
clientes con historial antes del corte

43 %
se fuga · desbalanceo leve

48 vs 113
días de recencia: vuelven vs se fugan

NO SUPERVISADO · K-MEANS (K = 4)

Cuatro perfiles de cliente accionables

VIP fieles

21,6 % de clientes

Compran cada ~2 semanas, ~7 pedidos, 82 productos distintos.

Fuga 13,4 %

Mayoristas

18,7 % de clientes

Pedidos grandes y espaciados: ticket ~597 £, 371 uds.

Fuga 36,7 %

Ocasionales

40,6 % de clientes

El grupo más grande: vuelven cuando se acuerdan de la marca.

Fuga 52,2 %

Dormidos

19,0 % de clientes

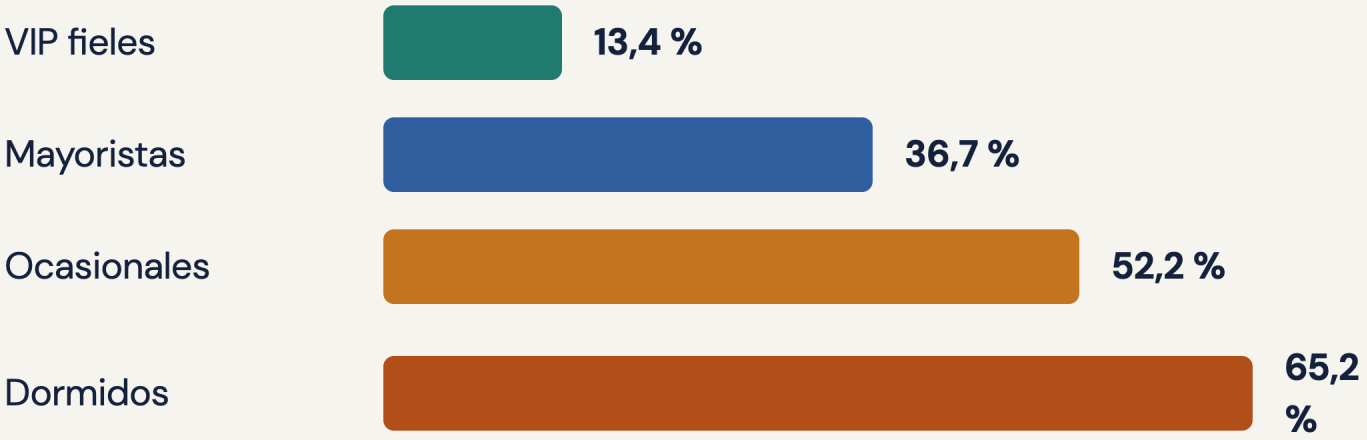
Una compra, hace tiempo y de bajo valor (~137 £).

Fuga 65,2 %

Pipeline: **log1p + StandardScaler** (corrige asimetría: Monetario de skew 17,5 a 0,4) → K elegido por codo, silueta y criterio de negocio.

VALIDACIÓN DE LA SEGMENTACIÓN

Sin mirar la fuga, los segmentos la separan del 13 % al 65 %



% de clientes de cada segmento que se fugan en los 90 días siguientes al corte

Comparativa de algoritmos

Algoritmo	Silueta
K-Means (K=4)	0,229
GMM (4)	0,058
DBSCAN	1 cluster

Los clientes forman una nube continua, sin «islas»: K-Means la corta en perfiles útiles.

SUPERVISADO · VALIDACIÓN CRUZADA (5 FOLDS)

Cinco modelos frente a un baseline que no detecta a nadie

Modelo (con GridSearch)	Recall	Precisión	F1	ROC-AUC
SVM (RBF) · elegido	0,819	0,586	0,683	0,745
Random Forest	0,784	0,593	0,676	0,747
Regresión Logística	0,757	0,602	0,670	0,749
Árbol de decisión	0,781	0,579	0,663	0,726
KNN	0,658	0,622	0,639	0,732
Baseline («siempre vuelve»)	0,000	—	0,000	0,500

Pipeline **log1p → escalado → modelo** con **class_weight="balanced"**. Selección por F1 en validación cruzada, nunca mirando el test. SVM, RF y LR están en **empate técnico** (diferencias menores que la desviación entre folds, ≈ 0,012).

EVALUACIÓN FINAL · 671 CLIENTES NUNCA VISTOS

El modelo detecta 8 de cada 10 clientes que se van

231
fugas detectadas a tiempo

60
fugas no detectadas (error caro)

179
incentivos «de más»

201
clientes fieles bien identificados

Métrica	CV	Test
Recall	0,819	0,794
Precisión	0,586	0,563
F1	0,683	0,659
ROC-AUC	0,745	0,728

Caída de solo 2–3 puntos: **no hay sobreajuste**. Las variables que más pesan: frecuencia, recencia, variedad de catálogo y gasto.

HALLAZGO CRÍTICO · LOS MEJORES CLIENTES

Una alerta VIP para las fugas que el modelo no veía

0/26

fugas VIP detectadas con el umbral global

→

11/26

con la alerta VIP (top 20 % de riesgo del segmento)

Un VIP que se va **no lo parece**: compró hace poco (recencia 11 días vs 14 de los que se quedan).

Pero el modelo **sí los ordena** por riesgo (ROC-AUC 0,76 dentro del segmento).

Umbral fijado solo con train (validación cruzada). Recall global de 0,794 a 0,832. Debe confirmarse con datos nuevos, porque el problema se descubrió al mirar el test.

PLAN DE ACCIÓN PARA EL RELANZAMIENTO

El comedero como puerta de entrada al catálogo

Segmento	Situación	Recompensa (sin descuentos)
VIP fieles	Pocas fugas, pero las más caras	Alerta VIP, contacto personal y acceso anticipado
Mayoristas	Pedidos grandes y espaciados	Envío gratis en pedidos grandes
Ocasionales	El grupo más grande	Puntos de fidelidad para que repitan
Dormidos	Una compra, alto riesgo	Inserto antivoracidad de regalo

Qelux se posiciona como **alta gama para mascotas**: un 15 % de descuento abarataría la marca. Las recompensas refuerzan el producto y la relación.

LIMITACIONES Y PRÓXIMOS PASOS

Se transfiere la metodología, no los números

Limitaciones

- Datos proxy: comercio británico de regalos, 2010-2011.
- Ventana de 90 días corta para mayoristas.
- Una sola fecha de corte.
- Predecir la fuga no dice qué incentivo funciona.

Próximos pasos

1. Recoger datos propios desde el día 1.
2. Reentrenar con varias fechas de corte.
3. Test A/B de recompensas por segmento.
4. Umbral según el coste real de cada acción.

CONCLUSIÓN

Cada comedero vendido es el inicio de una relación

Con este pipeline, Qelux sabrá desde el primer día quiénes son sus clientes, quién está en riesgo y qué hacer para que vuelvan.

Claudio Abreu Afonso · linkedin.com/in/claudioabreuafonso

